

# Disciplina: Estatística Aplicada a Negócios II

Prof. Vinicius Pereira do Sacramento

UNIVERSIDADE FEDERAL DO CARIRI  
Campus Juazeiro do Norte

1 de junho de 2022

# 1 Correlação e regressão linear

- Correlação
- Regressão linear simples


Numa população de pessoas, podemos dizer que as variáveis *peso* e *altura* são *correlacionadas positivamente*, pois a maioria dos indivíduos mais altos tendem a ser mais pesados que os indivíduos mais baixos,

## Diagrama de dispersão

Uma forma de visualizarmos se duas variáveis apresentam-se correlacionadas é através do *diagrama de dispersão*, onde os valores das variáveis são representados por pontos, num sistema cartesiano. A tabela abaixo relaciona a velocidade de impressão (em p.p.m.) e o preço de venda (R\$) de impressoras vendidas em um site de vendas pela internet.

| Velocidade de Impressão (p.p.m.) | Preço de Venda (R\$) |
|----------------------------------|----------------------|
| 12                               | 300,00               |
| 15                               | 350,00               |
| 16                               | 480,00               |
| 18                               | 900,00               |
| 32                               | 1.200,00             |
| 38                               | 2.000,00             |
| 40                               | 3.200,00             |

## Diagrama de Dispersão:



O diagrama de dispersão sugere uma correlação positiva entre preço de vendas e velocidade de impressão.

# Coeficiente de correlação linear de Pearson

## A ideia da construção do coeficiente de correlação

O valor do coeficiente de correlação não deve depender da unidade de media dos dados. Por exemplo, o coeficiente de correlação entre as variáveis *peso* e *altura*, observadas num certo conjunto de indivíduos, deve acusar o mesmo valor, independentemente se o peso for medido em *gramas* ou *quilogramas* e a altura em *metros* ou *centímetros*.

Para evitar o efeito da unidade de medida, consideramos os dados em termos da quantidade de desvio padrão que se afastam da média. Assim, a padronização de  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  é feita da seguinte forma:

$$x'_i = \frac{x_i - \bar{x}}{s_x} \quad y'_i = \frac{y_i - \bar{y}}{s_y} \quad (i = 1, 2, \dots, n)$$

onde:  $\bar{x}$ : média de  $x_1, x_2, \dots, x_n$ .

$s_x$ : desvio padrão de  $x_1, x_2, \dots, x_n$ ;

$\bar{y}$ : média de  $y_1, y_2, \dots, y_n$ ;

$s_y$ : desvio padrão de  $y_1, y_2, \dots, y_n$ .




Figura: Efeito da padronização das escalas.



Olhando a Figura do slide anterior, é possível notar que, no caso de correlação positiva, os pontos tendem a se localizar nos quadrantes I e III ( $x'$  e  $y'$  com o mesmo sinal). De forma análoga, quando houver correlação negativa, os pontos tendem a se localizar nos quadrantes II e IV ( $x'$  e  $y'$  com os sinais trocados). Assim, a soma dos produtos  $x'_i y'_i$  ( $i = 1, 2, \dots, n$ ) deve ter sinal positivo ou negativo, dependendo do sentido da correlação. Baseado nessa ideia, o coeficiente de correlação linear de Pearson,  $r$ , é definido pela seguinte expressão, em termos dos valores padronizados:

$$r = \frac{\sum_{i=1}^n x'_i y'_i}{n-1}$$

## Cálculo do coeficiente de correlação de Pearson

Efetuar o cálculo do coeficiente de correlação  $r$  através dos valores padronizados, além de ser bastante trabalhoso, tem o inconveniente de incorporar erros de arredondamento no cálculo dos valores padronizados, podendo comprometer o resultado final. Em geral, é conveniente usar a expressão a seguir:

$$r = \frac{n \sum_{i=1}^n x_i y_i - \left( \sum_{i=1}^n x_i \right) \left( \sum_{i=1}^n y_i \right)}{\sqrt{n \sum_{i=1}^n x_i^2 - \left( \sum_{i=1}^n x_i \right)^2} \sqrt{n \sum_{i=1}^n y_i^2 - \left( \sum_{i=1}^n y_i \right)^2}}$$

## Intervalo de variação de $r$

O coeficiente de correlação  $r$  é uma medida cujo valor se situa no intervalo compreendido pelos valores  $[-1, 1]$ :

$$-1 \leq r \leq 1$$

Assim temos:

$r = 1$ , correlação linear perfeita positiva;

$r = -1$ , correlação linear perfeita negativa;

$r = 0$ , não há relação linear entre as variáveis  $X$  e  $Y$ .

Dada a fórmula de  $r$ , calcularemos o coeficiente de correlação linear de Pearson para os dados dos preços de venda de impressoras e as suas respectivas velocidades de impressão.

|      |       | Velocidade de impressão (p.p.m.) | Preço de venda (R\$) |          |           |  |
|------|-------|----------------------------------|----------------------|----------|-----------|--|
| i    | $X_i$ | $Y_i$                            | $X_i^2$              | $Y_i^2$  | $X_i Y_i$ |  |
| 1    | 12    | 300                              | 144                  | 90000    | 3600      |  |
| 2    | 15    | 350                              | 225                  | 122500   | 5250      |  |
| 3    | 16    | 480                              | 256                  | 230400   | 7680      |  |
| 4    | 18    | 900                              | 324                  | 810000   | 16200     |  |
| 5    | 32    | 1200                             | 1024                 | 1440000  | 38400     |  |
| 6    | 38    | 2000                             | 1444                 | 4000000  | 76000     |  |
| 7    | 40    | 3200                             | 1600                 | 10240000 | 128000    |  |
| Soma | 171   | 8430                             | 5017                 | 16932900 | 275130    |  |

$$r = \frac{7(275130) - (171).(8430)}{\sqrt{7(5017) - (171)^2} \sqrt{7(16932900) - (8430)^2}} = 0,92$$

## Coeficiente de correlação populacional

De forma análoga, como definimos a medida descritiva de correlação entre as observações através do cálculo do coeficiente  $r$ , podemos definir, em termos probabilísticos, o *parâmetro* correlação entre duas variáveis aleatórias,  $X$  e  $Y$ , pelo valor esperado do produto destas variáveis padronizadas, ou seja:

$$\rho = \text{Corr}(X, Y) = E \left\{ \left( \frac{X - \mu_X}{\sigma_X} \cdot \frac{Y - \mu_Y}{\sigma_Y} \right) \right\}$$

em que:  $\mu_X = E(X)$ ,  $\mu_Y = E(Y)$ ,  $\sigma_X = \sqrt{\text{Var}(X)}$  e  $\sigma_Y = \sqrt{\text{Var}(Y)}$ .

## Inferência sobre $\rho$

Dada uma amostra aleatória simples  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ , de  $n$  observações do par de variáveis aleatórias  $(X, Y)$ , o coeficiente  $r$  pode ser considerado uma *estimativa* do verdadeiro e desconhecido coeficiente  $\rho$ .

É comum o interesse em verificar as seguintes hipóteses:

$H_0: \rho = 0$  (as variáveis  $X$  e  $Y$  são não correlacionadas);

$H_1: \rho \neq 0$  (as variáveis  $X$  e  $Y$  são correlacionadas).

Podendo, ainda, a hipótese alternativa indicar o sentido da correlação (teste unilateral), tal como  $H_1': \rho > 0$  ( $X$  e  $Y$  são correlacionadas positivamente) ou  $H_1'': \rho < 0$  ( $X$  e  $Y$  são correlacionadas negativamente).

Supondo X e Y com distribuições normais, podemos realizar o teste, calculando

$$t = \frac{r \cdot \sqrt{n-2}}{\sqrt{1-r^2}}$$

e usando como distribuição de referência a  $t$  de Student com  $gl = n - 2$ , realiza-se o teste para o nível de significância  $\alpha$  desejado.

## Exemplo 1:

Para os dados dos preços de venda de impressoras e as suas respectivas velocidades de impressão. Verificar se há uma correlação positiva entre o preço das impressoras e suas velocidades de impressão, com um nível de significância de 1%.

Temos as seguintes hipóteses:  $H_0: \rho = 0$   $H_1: \rho > 0$

Além disso, temos  $gl = n - 2 = 7 - 2 = 5$ ,  $r = 0,92$ ,

$t_{Cr} (t \text{ crítico}) \cong 3,365$  e  $t = \frac{0,92\sqrt{5}}{\sqrt{1-0,92^2}} \cong 5,25 > t_{Cr}$ , ou seja, a estatística  $t$  calculada, encontra-se na região de rejeição, logo rejeita-se  $H_0$ , com um nível de significância de 1%.



## Exercícios: "Barbetta, Reis e Bornia" páginas 323 e 324.

1. No processo de queima de massa cerâmica para pavimento, corpos de prova foram avaliados por três variáveis:  $X_1$  = retração linear (%),  $X_2$  = resistência mecânica (MPa) e  $X_3$  = absorção de água (%). Os resultados de 18 ensaios são apresentados a seguir:

| Ensaio | $X_1$ | $X_2$ | $X_3$ | Ensaio | $X_1$ | $X_2$ | $X_3$ |
|--------|-------|-------|-------|--------|-------|-------|-------|
| 1      | 8,70  | 38,42 | 5,54  | 10     | 13,24 | 60,24 | 0,58  |
| 2      | 11,68 | 46,93 | 2,83  | 11     | 9,10  | 40,58 | 3,64  |
| 3      | 8,30  | 38,05 | 5,58  | 12     | 8,33  | 41,07 | 5,87  |
| 4      | 12,00 | 47,04 | 1,10  | 13     | 11,34 | 41,94 | 3,32  |
| 5      | 9,50  | 50,90 | 0,64  | 14     | 7,48  | 35,53 | 6,00  |
| 6      | 8,58  | 34,10 | 7,25  | 15     | 12,68 | 38,42 | 0,36  |
| 7      | 10,68 | 48,23 | 1,88  | 16     | 8,76  | 45,26 | 4,14  |
| 8      | 6,32  | 27,74 | 9,92  | 17     | 9,93  | 40,70 | 5,48  |
| 9      | 8,20  | 39,20 | 5,63  | 18     | 6,50  | 29,66 | 8,98  |

Calcule o coeficiente de correlação de Pearson entre retração linear (%) e resistência mecânica (MPa-megapascal) para as 5 primeiras observações apresentadas na tabela acima. Apenas com estas observações, o teste detecta correlação real entre as duas variáveis?

## Exercícios (Continuação)

2. Com respeito aos 23 alunos de uma turma de estatística, foram observadas as variáveis *número de faltas* e *nota final na disciplina*. Esses dados acusaram a seguinte correlação, descrita pelo coeficiente de correlação de Pearson:  $r = -0,56$ . Comente as seguintes frases relativas à turma em estudo e ao coeficiente obtido.
- a. "Como  $r = -0,56$  (correlação negativa moderada), nenhum aluno com grande número de faltas tirou nota alta".
  - b. "Como as duas variáveis são correlacionadas, bastaria usar uma delas como critério de avaliação, pois uma acarreta a outra."
  - c. "Os dados observados mostraram uma leve tendência de que a nota final se relaciona inversamente ao número de faltas, ou seja, os alunos *frequentadores* tiveram, em geral, melhor desempenho nas avaliações do que os alunos que faltaram muito."

## Exercícios (Continuação)

3. Sejam  $X = \text{nota na prova do vestibular de matemática}$  e  $Y = \text{nota final na disciplina de cálculo}$ . Estas variáveis foram observadas em 20 alunos, ao final do primeiro período letivo de um curso de engenharia. Os dados são apresentados a seguir:

| $X$ | $Y$ | $X$ | $Y$ | $X$ | $Y$ | $X$ | $Y$ | $X$ | $Y$ |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 39  | 65  | 43  | 78  | 21  | 52  | 64  | 82  | 65  | 88  |
| 57  | 92  | 47  | 89  | 28  | 73  | 75  | 98  | 47  | 71  |
| 34  | 56  | 52  | 75  | 35  | 50  | 30  | 50  | 28  | 52  |
| 40  | 70  | 70  | 50  | 80  | 90  | 32  | 58  | 67  | 88  |

- Calcule a correlação entre a nota no vestibular de matemática e a nota na disciplina de cálculo. Interprete o resultado.
- Construa um diagrama de dispersão e verifique se algum aluno foge ao comportamento geral dos demais (ponto discrepante).
- Retire o valor discrepante detectado no item anterior e calcule novamente o coeficiente  $r$ . Interprete.
- Verifique se a correlação encontrada no item anterior é significativa. Faça o teste ao nível de significância de 5% e interprete o resultado.

4. No desenvolvimento computacional de um escalonador, foram realizados alguns testes em 16 condições experimentais diferentes. O desempenho do escalonador foi observado através da quantidade de trabalho executado, num certo período de tempo: em processamento de textos ( $X_1$ ), em processamento interativo de dados ( $X_2$ ) e em processamento de dados em *batch* ( $X_3$ ). Os coeficientes de correlação calculados sobre as 16 observações foram:

|       | $X_1$ | $X_2$ | $X_3$ |
|-------|-------|-------|-------|
| $X_1$ | 1,00  | 0,18  | 0,86  |
| $X_2$ | 0,18  | 1,00  | 0,02  |
| $X_3$ | 0,86  | 0,02  | 1,00  |

Que informações podem ser extraídas dessa matriz de correlações? Há evidências de que nas situações em que o desempenho é melhor para um atributo (por exemplo, processamento de texto), ele também tende a ser melhor em outro atributo (por exemplo processamento interativo de dados)?

# Introdução

Iniciaremos o estudo de regressão com a formulação mais simples, relacionando uma variável  $Y$ , chamada de variável *resposta* ou *dependente*, com uma variável  $X$ , denominada de variável *explicativa* ou *independente*.

## Exemplo 2:

Exemplo (Stevenson (2001), p345): “Suponhamos que tenhamos coletado dados de vendedores de carros do bairro, sobre quilometragem e preços de carros de 1975 de certa marca e com determinado equipamento (ar-condicionado, direção hidráulica, etc.). Os dados amostrais, que poderiam se originar de uma amostra aleatória de vendedores da região, se apresentariam mais ou menos como os dados da Tabela no próximo slide:

| t          | $x_i$                  | $y_i$               |
|------------|------------------------|---------------------|
| Observação | Quilometragem (1000's) | Preço de venda (\$) |
| 1          | 40                     | 1000                |
| 2          | 30                     | 1500                |
| 3          | 30                     | 1200                |
| 4          | 25                     | 1800                |
| 5          | 50                     | 800                 |
| 6          | 60                     | 1000                |
| 7          | 65                     | 500                 |
| 8          | 10                     | 3000                |
| 9          | 15                     | 2500                |
| 10         | 20                     | 2000                |
| 11         | 55                     | 800                 |
| 12         | 40                     | 1500                |
| 13         | 35                     | 2000                |
| 14         | 30                     | 2000                |

Tabela: Dados do Exemplo 2.




Figura: Gráfico de dispersão: Quilometragem *versus* preço de venda

Os dados parecem sugerir uma relação linear entre quilometragem e preço de venda.



Observe que é razoável supor uma relação aproximadamente linear entre  $X$  e  $Y$ . Contudo, os pontos não estão exatamente sobre uma reta, provavelmente por causa da existência de fatores não controláveis no processo. Vamos supor, então, que o valor esperado de  $Y$  varie com  $X$ , de acordo com uma equação de primeiro grau, ou seja:

$$E\{Y\} = a + bX$$

onde  $a$  e  $b$  são os parâmetros do modelo.

Seja um conjunto de observações  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ . O chamado modelo de *regressão linear simples* para as observações é dado por

$$Y_i = a + bx_i + \epsilon_i$$

onde:  $Y_i$  é a variável aleatória associada à  $i$ -ésima observação de  $Y$ ;  
 $\epsilon$


$\epsilon_i$  é o erro aleatório da  $i$ -ésima observação, isto é, o efeito de uma infinidade de fatores que estão afetando a observação de  $Y$  de forma aleatória.

Note que é razoável supor  $E\{\epsilon_i\} = 0$  ( $i = 1, 2, \dots, n$ ). Assim, considerando  $X$  uma variável controlável (não aleatória), temos, pelas propriedades do valor esperado:

$$E\{Y_i\} = E\{a + bx_i + \epsilon_i\} = E\{a\} + E\{bx_i\} + E\{\epsilon_i\} = a + bx_i$$

# Método dos mínimos quadrados

Para construirmos o modelo  $E\{Y\} = a + bX$ , precisamos obter estimativas para  $a$  e  $b$ , a partir de um conjunto de observações  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ . Ou seja, queremos encontrar a reta que passe o *mais próximo possível* dos pontos observados.



O meio mais usual para estimar  $a$  e  $b$  é o *método de mínimos quadrados*, que consiste em fazer com que a soma dos erros quadráticos seja a menor possível. Considerando,  $Y_i = a + bx_i + \epsilon_i$ , temos que o erro aleatório da  $i$ -ésima observação ( $i = 1, 2, \dots, n$ ) é dado por:

$$\epsilon_i = Y_i - (a + bx_i)$$

O método consiste em obter os valores de  $a$  e  $b$  que minimizam a expressão:

$$S = \sum \epsilon_i^2 = \sum \{y_i - (a + bx_i)\}^2$$

que pode ser feito igualando as derivadas parciais a zero, ou seja.

$$\frac{\partial S}{\partial a} = 0 \text{ e } \frac{\partial S}{\partial b} = 0$$

Assim,

$$\frac{\partial S}{\partial a} = -2 \sum \{y_i - (a + bx_i)\} = 0$$

$$\sum y_i - na - b \sum x_i = 0$$

$$a = \frac{\sum y_i - b \sum x_i}{n} \quad (1)$$

E,

$$\frac{\partial S}{\partial b} = -2 \sum \{y_i - (a + bx_i)\} x_i = 0$$
$$\sum y_i x_i - a \sum x_i - b \sum x_i^2 = 0$$

$$b = \frac{\sum y_i x_i - a \sum x_i}{\sum x_i^2} \quad (2)$$

Substituindo a equação (1) na (2),

$$b = \frac{\sum y_i x_i - \frac{(\sum y_i - b \sum x_i) \sum x_i}{n}}{\sum x_i^2}$$

$$b = \frac{n \sum y_i x_i - \sum y_i \sum x_i + b(\sum x_i)^2}{n \sum x_i^2}$$

$$bn \sum x_i^2 - b(\sum x_i)^2 = n \sum y_i x_i - \sum y_i \sum x_i$$

$$b = \frac{n \sum y_i x_i - \sum y_i \sum x_i}{n \sum x_i^2 - (\sum x_i)^2} \quad (3)$$

resultando nas seguintes estimativas para  $a$  e  $b$ , as quais chamaremos de  $\hat{a}$  e  $\hat{b}$ , respectivamente:

$$\hat{b} = \frac{n \sum (x_i y_i) - (\sum x_i)(\sum y_i)}{n \sum x_i^2 - (\sum x_i)^2}$$

$$\hat{a} = \frac{\sum y_i - \hat{b} \sum x_i}{n}$$

em que  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  é uma amostra observada.



A chamada equação (reta) de regressão é dada por:

$$\hat{y} = \hat{a} + \hat{b}x$$

Para cada valor  $x_i$  ( $i = 1, 2, \dots, n$ ), temos, pela equação de regressão, o valor *predito*:

$$\hat{y}_i = \hat{a} + \hat{b}x_i$$

A diferença entre os valores observados e os preditos é chamada de resíduo:

$$e_i = y_i - \hat{y}_i$$

O resíduo relativo à  $i$ -ésima observação ( $e_i$ ) pode ser considerado uma estimativa do erro aleatório ( $\epsilon_i$ ) desta observação.

| $t$<br>Observação | $x_i$<br>Quilometragem (1000's) | $y_i$<br>Preço de venda (\$) | $x_i^2$ | $x_i y_i$ | $y_i^2$  |
|-------------------|---------------------------------|------------------------------|---------|-----------|----------|
| 1                 | 40                              | 1000                         | 1600    | 40000     | 1000000  |
| 2                 | 30                              | 1500                         | 900     | 45000     | 2250000  |
| 3                 | 30                              | 1200                         | 900     | 36000     | 1440000  |
| 4                 | 25                              | 1800                         | 625     | 45000     | 3240000  |
| 5                 | 50                              | 800                          | 2500    | 40000     | 640000   |
| 6                 | 60                              | 1000                         | 3600    | 60000     | 1000000  |
| 7                 | 65                              | 500                          | 4225    | 32500     | 250000   |
| 8                 | 10                              | 3000                         | 100     | 30000     | 9000000  |
| 9                 | 15                              | 2500                         | 225     | 37500     | 6250000  |
| 10                | 20                              | 2000                         | 400     | 40000     | 4000000  |
| 11                | 55                              | 800                          | 3025    | 44000     | 640000   |
| 12                | 40                              | 1500                         | 1600    | 60000     | 2250000  |
| 13                | 35                              | 2000                         | 1225    | 70000     | 4000000  |
| 14                | 30                              | 2000                         | 900     | 60000     | 4000000  |
| $\Sigma$          | 505                             | 21600                        | 21825   | 640000    | 39960000 |


Tabela: Regressão linear simples (continuação do exemplo 2.)

$$\hat{b} = \frac{14.(640000) - (505).(21600)}{14.(21825) - (505)^2} = -38,5552$$

$$\hat{a} = \frac{21600 - (-38.5552).(505)}{14} = 2933,6$$

Assim, temos a seguinte reta de regressão:

$$\hat{y} = 2933,6 - 38,5552x$$



**Figura:** Diagrama de dispersão dos dados do exemplo 2 e a reta de regressão ajustada a esses dados.

A partir dos dados, construímos um modelo, o qual nos permite *predizer* o preço dos automóveis ( $\hat{y}$ ), a partir da quilometragem rodada ( $x$ ). Por exemplo, em média, a cada 10.000 quilômetros rodados  $x = 10$ , esperamos uma perda de valor de  $(-38,555)(10) = 385\$$ . A tabela que segue, mostra que os valores preditos do modelo estão bastante próximos dos valores observados nos dados.

Tabela: Valores preditos [ $\hat{y}_i = 2933,6 - 38,5552x_i$ ] e resíduos ( $e_i = y_i - \hat{y}_i$ ).

| $t$<br>Observação | $x_i$<br>Quilometragem (1000's) | $y_i$<br>Preço de venda (\$) | $\hat{y}_i$ | $e_i$  |
|-------------------|---------------------------------|------------------------------|-------------|--------|
| 1                 | 40                              | 1000                         | 1391,4      | -391,4 |
| 2                 | 30                              | 1500                         | 1777,0      | -277,0 |
| 3                 | 30                              | 1200                         | 1777,0      | -577,0 |
| 4                 | 25                              | 1800                         | 1969,7      | -169,7 |
| 5                 | 50                              | 800                          | 1005,9      | -205,9 |
| 6                 | 60                              | 1000                         | 620,3       | 379,7  |
| 7                 | 65                              | 500                          | 427,5       | 72,5   |
| 8                 | 10                              | 3000                         | 2548,1      | 452,0  |
| 9                 | 15                              | 2500                         | 2355,3      | 144,7  |
| 10                | 20                              | 2000                         | 2162,5      | -162,5 |
| 11                | 55                              | 800                          | 813,1       | -13,1  |
| 12                | 40                              | 1500                         | 1391,4      | 108,6  |
| 13                | 35                              | 2000                         | 1584,2      | 415,8  |
| 14                | 30                              | 2000                         | 1777,0      | 223,1  |
|                   | 505                             | 21600                        |             |        |

O coeficiente  $\hat{b}$  fornece uma estimativa da variação esperada de  $Y$ , a partir da variação de *uma* unidade em  $X$ . O sinal deste coeficiente indica o sentido da variação.

## Análise de variância do modelo

Se  $X$  não influencia  $Y$ , então o valor esperado de  $Y$  pode ser estimado simplesmente pela média aritmética ( $\bar{y}$ ) das observações de  $Y$ . Mas se existe influência de  $X$  sobre  $Y$ , então deve haver algum ganho em considerar a equação de regressão ( $\hat{y} = \hat{a} + \hat{b}x$ ). Este ganho, pode ser avaliado ao comparar os resíduos nas duas situações.



Para  $i = 1, 2, \dots, n$ , sejam:

- a.  $y_i - \bar{y}$  (desvios em relação à média aritmética - não levam em consideração a relação entre  $Y$  e  $X$ );
- b.  $y_i - \hat{y}_i$  (desvios em relação aos valores preditos pela equação de regressão - consideram uma relação linear entre  $Y$  e  $X$ );
- c.  $\hat{y}_i - \bar{y}$  (desvios dos valores preditos em relação à média aritmética).




Figura: Ilustração dos desvios numa situação hipotética.

As somas dos quadrados dos desvios satisfazem à seguinte equação:

$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$$

*variação total*
*variação explicada pela equação de regressão*
*variação não explicada*

E chamaremos de *coeficiente de determinação* a seguinte razão:

$$R^2 = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2} = \frac{\text{variação explicada}}{\text{variação total}}$$

O coeficiente de determinação é uma media descritiva da proporção da variação de  $Y$  que pode ser *explicada* por variações em  $X$ , segundo o modelo especificado.

## Continuação do Exemplo 2:

| $x_i$ | $y_i$ | $\hat{y}_i$ | $\bar{y}$ | $y_i - \bar{y}$ | $y_i - \hat{y}$ | $\hat{y}_i - \bar{y}$ | $(y_i - \bar{y})^2$ | $(y_i - \hat{y})^2$ | $(\hat{y}_i - \bar{y})^2$ |
|-------|-------|-------------|-----------|-----------------|-----------------|-----------------------|---------------------|---------------------|---------------------------|
| 40    | 1000  | 1391,4      | 1471,4    | -471,4          | -391,4          | -80,0                 | 222244,9            | 153194,0            | 6404,6                    |
| 30    | 1500  | 1777,0      | 1471,4    | 28,6            | -277,0          | 305,5                 | 816,3               | 76701,3             | 93343,3                   |
| 30    | 1200  | 1777,0      | 1471,4    | -271,4          | -577,0          | 305,5                 | 73673,5             | 332871,3            | 93343,3                   |
| 25    | 1800  | 1969,7      | 1471,4    | 328,6           | -169,7          | 498,3                 | 107959,2            | 28806,6             | 248299,3                  |
| 50    | 800   | 1005,9      | 1471,4    | -671,4          | -205,9          | -465,6                | 450816,3            | 42374,2             | 216763,4                  |
| 60    | 1000  | 620,3       | 1471,4    | -471,4          | 379,7           | -851,1                | 222244,9            | 144172,1            | 724419,8                  |
| 65    | 500   | 427,5       | 1471,4    | -971,4          | 72,5            | -1043,9               | 943673,5            | 5252,6              | 1089734,7                 |
| 10    | 3000  | 2548,1      | 1471,4    | 1528,6          | 452,0           | 1076,6                | 2336530,6           | 204258,8            | 1159113,7                 |
| 15    | 2500  | 2355,3      | 1471,4    | 1028,6          | 144,7           | 883,8                 | 1057959,2           | 20945,3             | 781184,5                  |
| 20    | 2000  | 2162,5      | 1471,4    | 528,6           | -162,5          | 691,1                 | 279387,8            | 26406,3             | 477579,7                  |
| 55    | 800   | 813,1       | 1471,4    | -671,4          | -13,1           | -658,4                | 450816,3            | 171,0               | 433429,4                  |
| 40    | 1500  | 1391,4      | 1471,4    | 28,6            | 108,6           | -80,0                 | 816,3               | 11794,0             | 6404,6                    |
| 35    | 2000  | 1584,2      | 1471,4    | 528,6           | 415,8           | 112,7                 | 279387,8            | 172910,4            | 12711,8                   |
| 30    | 2000  | 1777,0      | 1471,4    | 528,6           | 223,1           | 305,5                 | 279387,8            | 49751,3             | 93343,3                   |
|       |       |             |           |                 |                 |                       | 6705714,3           | 1269609,1           | 5436075,5                 |

E o coeficiente de determinação:

$$R^2 = \frac{5436075,5}{6705714,3} \cong 0,81$$

Em termos dos 14 pontos amostrais estudados, a variância do preço dos carros é explicada, em parte, pela variação quilometragem rodada ( $R^2 = 81\%$  de explicação) e em parte ( $1 - R^2 = 19\%$ ) devido a outros fatores intervenientes no processo. No caso do modelo de regressão linear simples,  $R^2$  coincide, numericamente, com o quadrado do coeficiente de correlação  $r$  de *Pearson*.

**Processo simplificado de cálculo** Soma de quadrados totais:

$$SQT = \sum (y_i - \bar{y})^2 = \sum y_i^2 - \frac{(\sum y_i)^2}{n}$$

Soma de quadrados do erro ou soma de quadrados dos resíduos:

$$SQE = \sum (y_i - \hat{y}_i)^2 = \sum y_i^2 - \hat{a} \sum y_i - \hat{b} \sum x_i y_i$$

Soma de quadrados da regressão:

$$SQR = \sum (\hat{y}_i - \bar{y})^2 = SQT - SQE$$

E o coeficiente de determinação:

$$R^2 = \frac{SQR}{SQT} = 1 - \frac{SQE}{SQT}$$

Cada soma de quadrados está associada a certo número de *graus de liberdade*. Os desvios de cada observação em relação às estimativas de  $E\{Y\}$  têm graus de liberdade iguais a  $n$  subtraído do número de parâmetros estimados em  $E\{Y\}$ . Assim, os desvios  $y_i - \bar{y}$  têm  $n - 1$  graus de liberdade; e os desvios  $y_i - \hat{y}_i$  têm  $n - 2$  graus de liberdade.

A soma de quadrados dividida pelo correspondente grau de liberdade fornece o *quadrado médio* ou *variância*. E a razão entre o *quadrado médio da regressão* e o *quadrado médio do erro* resulta na *chamada razão F*

Tabela: Análise de variância (Anova) da regressão linear simples.


| Fonte de variação | gl      | SQ                                   | QM                | Razão F       |
|-------------------|---------|--------------------------------------|-------------------|---------------|
| Regressão         | 1       | $SQR = \sum (\hat{y}_i - \bar{y})^2$ | $QMR = SQR/1$     | $f = QMR/QME$ |
| Erro              | $n - 2$ | $SQE = \sum (y_i - \hat{y}_i)^2$     | $QME = SQE/n - 2$ |               |
| Total             | $n - 1$ | $SQT = \sum (y_i - \bar{y})^2$       | $QMT = SQT/n - 1$ |               |

Continuação do Exemplo 2: Tabela da Anova:

| <i>Fonte de variação</i> | <i>gl</i> | <i>SQ</i> | <i>MQ</i> | <i>Razão F</i> |
|--------------------------|-----------|-----------|-----------|----------------|
| Regressão                | 1         | 5436075,5 | 5436075,5 | 51,4           |
| Erro                     | 12        | 1269609,1 | 105800,8  |                |
| Total                    | 13        | 6705714,3 |           |                |

## Inferências sobre o modelo de regressão

Podemos imaginar que existe uma *equação de regressão verdadeira*, a qual poderia ser obtida se pudéssemos realizar o experimento com infinitos ensaios. Possíveis amostras de  $(X, Y)$  devem seguir, aproximadamente, o comportamento da *equação de regressão verdadeira*, de tal forma que a variação dos pontos em torno desta equação pode ser caracterizada por uma distribuição de probabilidades.



**Figura:** Ilustração da distribuição de probabilidade em torno da verdadeira regressão.



## Suposições do modelo

Considerando novamente o modelo de regressão linear simples:

$$Y_i = a + bx_i + \epsilon_i$$

vamos supor:

- 1 os termos  $(\epsilon_1, \epsilon_2, \dots, \epsilon_n)$  são *independentes*;
- 2  $E\{\epsilon_i\} = 0$ ;
- 3  $V\{\epsilon_i\} = \sigma^2$ ; e
- 4  $\epsilon_i$  tem distribuição normal ( $i = 1, 2, \dots, n$ ).

e testar as hipóteses do tipo  $H_0 : b = b_0$  contra  $H_1 : b \neq b_0$  ( $b_0$  é uma constante especificada), calculando

$$t = \frac{\hat{b} - b_0}{s_{\hat{b}}}$$

Considerando a grandeza

$$s_e = \sqrt{QME} = \sqrt{\frac{SQE}{n-2}} = \sqrt{\frac{(\sum y^2) - a(\sum y) - b(\sum xy)}{n-2}}$$

que corresponde ao *desvio padrão dos resíduos*, ou seja, uma estimativa do desvio padrão do *erro aleatório*,  $\sigma$ .

A partir da equação anterior, podemos ter uma estimativa do *erro padrão* de  $b$  por

$$s_{\hat{b}} = s_e \cdot \sqrt{\frac{1}{\sum x^2 - \left[\frac{(\sum x)^2}{n}\right]}}$$

e comparando com o valor tabelado  $t_c$  da distribuição  $t$  com  $gl = n - 2$ . Se  $b_0 = 0$ , este teste é equivalente ao *teste F* visto anteriormente.


Para o caso do Exemplo 2 estudado aqui temos:

$$s_{\hat{b}} = \sqrt{\frac{39960000 - 2933,6(21600) + 38,6(640000)}{12}} \sqrt{\frac{1}{21825 - [\frac{(505)^2}{14}]}}$$

$$s_{\hat{b}} = (328,9174)(0,0166) \approx 5,46$$

E ainda,

$$t_{Calculado} = \frac{\hat{b} - b_0}{s_{\hat{b}}} = \frac{-38,6 - 0}{5,46} \approx -7,07$$



**Figura:** Regiões críticas e de não rejeição, da distribuição t-student com 12 graus de liberdade e  $t(\text{tabelado})$  obtido para nível de significância  $\alpha = 0,05$ .

Logo, rejeita-se a hipótese nula com nível de significância de 5%.

Dado certo nível de confiança  $\gamma$ , podemos obter na tabela da distribuição  $t$  o valor correspondente de  $t_\gamma$ , com  $gl = n - 2$ , e construir um intervalo de confiança para  $b$  por

$$IC(b, \gamma) = \hat{b} \pm t_\gamma \cdot s_{\hat{b}}$$

## Exercícios: "Stevenson" páginas 364.

1. Determine quais os coeficientes angulares para os dados abaixo são significativos ao nível de 0,05.

|       | a. | b.    | c.  | d.  | e.   | f.    |
|-------|----|-------|-----|-----|------|-------|
| $b$   | 4  | -0,15 | 1,2 | 0,6 | -212 | 0,015 |
| $s_b$ | 1  | 0,10  | 0,6 | 0,2 | 38   | 0,001 |
| $n$   | 12 | 20    | 25  | 31  | 50   | 100   |

2. Determine intervalos de 99% de confiança para cada um dos seguintes coeficientes de regressão e indique quais coeficientes são significativos.

|       | a.  | b.   | c.    | d.  | e.   |
|-------|-----|------|-------|-----|------|
| $b$   | 8,2 | 0,13 | 5,213 | 145 | -7,1 |
| $s_b$ | 4,1 | 0,04 | 1,50  | 40  | 3,0  |
| $n$   | 50  | 30   | 20    | 66  | 9    |



3. Use os dados abaixo para o seguinte:
- Calcule a equação de regressão;
  - Calcule  $S_e$  e depois  $S_b$ ;
  - Determine se  $b$  é significativo usando um intervalo de confiança com  $\alpha = 0,05$ .

| Escores dos testes | A  | B  | C  | D  | E  | F  | G  | H  | I  | J  | Totais |
|--------------------|----|----|----|----|----|----|----|----|----|----|--------|
| 1º teste           | 80 | 95 | 88 | 98 | 94 | 74 | 81 | 86 | 90 | 69 | 855    |
| 2º teste           | 78 | 90 | 85 | 98 | 90 | 76 | 80 | 78 | 89 | 62 | 826    |

4. Escreva a equação que descreveria os dados do exercício precedente se o escore do segundo teste fosse em cada caso exatamente igual ao do primeiro.
5. Calcule  $r^2$  usando os dados abaixo

|   |   |   |   |   |   |   |   | Totais |
|---|---|---|---|---|---|---|---|--------|
| x | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 28     |
| y | 2 | 4 | 5 | 6 | 7 | 7 | 9 | 40     |

6. Explique por que  $r^2$  nunca pode ser negativo.

7. Calcule  $r^2$  em cada um dos casos seguintes:

|         | a.    | b.    | c.   | d.   | e.   |
|---------|-------|-------|------|------|------|
| $S_e^2$ | 14400 | 14400 | 2025 | 2025 | 606  |
| $S_y^2$ | 28800 | 57600 | 2500 | 2200 | 6060 |

9. Calcule  $F$  para cada um dos casos abaixo e determine quais valores são significativos ao nível 0,01.

|    | n   | $\sum x$ | $\sum y$ | $\sum xy$ | $\sum x^2$ | $\sum y^2$ |
|----|-----|----------|----------|-----------|------------|------------|
| a. | 25  | 60       | 52       | 200       | 400        | 592        |
| b. | 50  | 15       | 20       | 146       | 204,5      | 400        |
| c. | 100 | 20       | 25       | -3,5      | 5          | 125        |

10. Use a análise da variância para analisar as estatísticas (a) a (e) do Exercício 7, utilizando  $\alpha = 0,05$  e  $n = 42$ . Suponha  $n - 1$  para calcular  $S_y^2$ .

## Exercícios: "Barbetta" páginas 344.

5. Um administrador de uma grande sorveteria anotou por um longo período de tempo a *temperatura média diária*, em  $^{\circ}\text{C}$  ( $X$ ), e o volume de vendas diárias de sorvete, em kg ( $Y$ ). Com os dados, foi ajustada a seguinte equação de regressão:  $y = 0,5 + 1,8x$ , com  $R^2 = 80$
- Pergunta-se:
- Qual é o consumo esperado de sorvete num dia de  $27^{\circ}\text{C}$  ?
  - Qual é o incremento esperado nas vendas de sorvete a cada  $1^{\circ}\text{C}$  de aumento de temperatura?

## Exercícios: "Barbetta" páginas 344. (continuação)

6. No processo de queima de massa cerâmica, avaliou-se o efeito da temperatura do forno ( $X$ ) sobre a resistência mecânica da massa queimada ( $Y$ ). Foram realizados 6 ensaios com níveis de temperatura equidistantes, os quais designaremos por 1, 2, 3, 4, 5, e 6. Os valores obtidos de resistência mecânica (MPa) foram: 41, 42, 50, 53, 54 e 60, respectivamente. Pedem-se:
- As estimativas de  $\alpha$  e  $\beta$  da equação de regressão  $E(Y) = \alpha + \beta x$ ;
  - O coeficiente  $R^2$ ;
  - O desvio padrão dos resíduos,  $S_e$ .
  - O teste estatístico  $H_0 : \beta = 0$ .

## Exercícios: "Barbetta" páginas 344. (continuação 2)

7. A tabela a seguir relaciona os pesos (em centenas de kg) e as taxas de rendimento de combustível em rodovia (km/litro), numa amostra de 10 carros de passeio novos.

|            |    |    |    |    |    |    |    |    |    |    |
|------------|----|----|----|----|----|----|----|----|----|----|
| Peso       | 12 | 13 | 14 | 14 | 16 | 18 | 19 | 22 | 24 | 26 |
| Rendimento | 16 | 14 | 14 | 13 | 11 | 12 | 09 | 09 | 08 | 06 |

- Calcule o coeficiente de correlação de Pearson;
- Considerando o resultado do item (a), como você avalia o relacionamento entre peso e rendimento, na amostra observada?
- Para estabelecer uma equação de regressão, qual deve ser a variável dependente e qual deve ser a variável independente? Justifique a sua resposta.
- Estabeleça a equação de regressão, considerando a resposta do item (c).

## Exercícios: "Barbetta" páginas 344. (continuação 3)

- e. Apresente o diagrama de dispersão e a reta de regressão obtida em (d).
- f. Você considera adequado o ajuste do modelo de regressão do item (d)? Dê uma medida dessa adequação, interpretando-a.
- g. Qual é o rendimento esperado para um carro de 2.000 kg? Justifique sua resposta. Lembrete: os dados de peso na tabela estão em centenas de *kg*.
- h. Você considera seu estudo capaz de predizer o rendimento esperado de um veículo com peso de 7.000 kg? Justifique sua resposta.

## Exercícios: "Barbetta" páginas 345.

8. Para verificar a viabilidade de incluir os resíduos da queima de carvão mineral na composição do cimento, foram feitos ensaios com cimento contendo de 0 a 9% de cinza de carvão; e media a resistência à compressão (em MPa), após 28 dias. Os resultados foram os seguintes .

| Carvão (%)        | 0    | 1    | 2    | 3    | 4    | 5    | 6    |
|-------------------|------|------|------|------|------|------|------|
| Resistência (MPa) | 38,5 | 40,2 | 42,1 | 37,5 | 41,1 | 36,9 | 38,2 |

- Estabeleça a equação de regressão;
- Calcule  $R^2$ ?
- Teste se o coeficiente angular pode ser zero. Use  $\alpha = 0,05$ .
- Os resultados mostram evidência de que o uso de cinza de carvão mineral na composição do cimento diminui a sua resistência em 28 dias?

# Gabarito: "Stevenson" p364.

1.  $t_{teste} = \frac{b-0}{s_b}$  (se  $n > 32$ , use  $z \approx t$ )

|              | a.           | b.            | c.            | d.           | e.           | f.           |
|--------------|--------------|---------------|---------------|--------------|--------------|--------------|
| $t_{teste}$  | 4            | -1,5          | 2,0           | 3,0          | -5,58        | 15,0         |
| $t_{tabela}$ | 2,228        | 2,101         | 2,069         | 2,045        | 1,96         | 1,96         |
| Decisão      | significante | aceitar $H_0$ | aceitar $H_0$ | significante | significante | significante |

2. os intervalos são  $b \pm tS_b$  (não significantes se 0 está no intervalo)

- a.  $8,2 \pm 2,58(4,1)$  ou -2,38 a 18,78 (não significativa);
- b.  $0,13 \pm 2,76(0,04)$  ou 0,02 a 0,24 ;
- c.  $5,213 \pm 2,878(1,5)$  ou 0,90 a 9,53;
- d.  $145 \pm 2,58(40)$  ou 41,8 a 248,2;
- e.  $-7,1 \pm 3,499(3,0)$  ou -17,6 a +3,4 (não significativa).

- 3. a.  $y_c = -4,02 + 1,013x$ ;
- b.  $S_e = 3,33$  e  $S_b = 0,12$  ;
- c.  $1,013 \pm 2,77(0,12)$  ou 0,736 a 1,29 (significante).



## Gabarito: "Stevenson" p364. (continuação)

4.  $y_c = 1x$
5.  $R^2 = 0,999$
6.  $R^2 = 1 - (\frac{S_e^2}{S_y^2})$ ;  $S_e^2$  deve ser sempre menor que  $S_y^2$
7.  $R^2 = 1 - (\frac{S_e^2}{S_y^2})$ .
  - a. 0,5;
  - b. 0,75;
  - c. 0,19;
  - d. 0,08;
  - e. 0,9.

## Gabarito: "Barbetta" p344 e 345.

- 6
- a.  $a = 36,6$  e  $b = 3,83$
  - b.  $R^2 = 0,95$
  - c.  $S_e = 1,836$
  - d. Rejeita  $H_0$ , pois  $f=76,1$  ( $p < 0,0001$ ) ou  $t=8,72$  ( $p < 0,0001$ ).
- 7
- a.  $r = -0,96$
  - b. Correlação negativa forte.
  - c. Variável dependente: consumo; e variável independente: peso.
  - d.  $(\text{consumo}) = 22,25 - 0,62 (\text{peso})$ .
  - f. Sim, verifica-se pelo gráfico do item (e) que uma relação linear parece adequar-se bem ao presente problema. Além disso, tem-se um coeficiente de determinação próximo de 1 ( $R^2 = 0,92$ )
  - g. 9,85 km/l
  - h. Não, pois os veículos estudados estavam na faixa de 1200 a 2600 kg e, portanto, a equação de regressão deve ser usada apenas nesta faixa.

Gabarito: "Barbetta" p345.

- 8
- a.  $\hat{y} = 40,22 - (0,35)x$
  - b. 0,27
  - c. Aceita  $H_0: \beta = 0$  (Teste bilateral:  $t=-1,72$ ;  $0,10 < p < 0,20$ ).
  - d. Não.

## Bibliografia:

- **Estatística para cursos de engenharia e informática.**  
BARBETTA, Pedro Alberto; REIS, Marcelo Menezes;  
BORNIA, Antonio Cezar . 3. ed. São Paulo, SP.
- **Estatística Básica: probabilidade e inferência**  
MORETTIN, Luiz Gonzaga; volume único. Pearson Prentice  
Hall, 2010.
- **Estatística Aplicada à Informática e às suas novas  
tecnologias - Volume 2** COSTA, Giovani Glaucio de Oliveira.  
Rio de Janeiro: Editora Ciência Moderna Ltda., 2015.
- **Estatística Aplicada à Administração.** STEVENSON, W.J.  
Harbra Ltda. 1981.